PANDUAN PERSIAPAN KELAS & PRESENTASI

Mata Kuliah: Pembelajaran Mesin Mendalam Lanjut (PMML) | MKA FMIPA UGM

Nama Mahasiswa: Frans Alwan Purba	**Dosen Pengampu:** Dr. Afiahayati, S.Kom., M.Cs.
NIM: 25/563545/PPA/07116	**Topik:** Replikasi MNIST & Eksperimen Regularisasi
Framework: TensorFlow 2.21 / Keras 3.15	**Repositori:** github.com/fransalwan/mnist-regularization-experiments-pmml

1. Objektif & Latar Belakang Tugas

Tugas Assignment 2 bertujuan untuk memvalidasi pemahaman mahasiswa mengenai konsep *Learning Strategy* dan teknik pencegahan *overfitting* pada Deep Neural Network. Eksperimen diawali dengan mereplikasi model dasar (Slide 20–23) berupa Artificial Neural Network (Feedforward MLP) untuk klasifikasi digit MNIST, lalu mengevaluasi secara komparatif lima skenario regularisasi: L1, L2, Dropout, Early Stopping, dan kombinasi L1 + Dropout.

2. Landasan Teori & Formulasi Matematis

A. Mengapa Overfitting Terjadi?

Overfitting terjadi ketika model memiliki kapasitas parameter yang berlebih dibandingkan kompleksitas pola intrinsik data. Model menghafal *noise* dan artefak spesifik pada training set, yang ditandai dengan penurunan kontinu pada training loss namun diikuti saturasi atau peningkatan pada validation loss (gap generalisasi melebar).

B. Komparasi Empat Pendekatan Regularisasi

1. Regularisasi L1 (Lasso Penalty):
Menambahkan suku penalti nilai absolut bobot pada fungsi objektif:

$$J(W) = L_{CE}(y, \hat{y}) + \lambda \Sigma |w_{ij}|$$

Mekanisme turunan menghasilkan gradien konstan ±λ. Hal ini memaksa bobot fitur yang tidak signifikan (seperti piksel latar belakang MNIST yang bernilai 0) menjadi **tepat nol (sparsity)**. L1 berfungsi sekaligus sebagai seleksi fitur terintegrasi.

2. Regularisasi L2 (Ridge / Weight Decay):
Menambahkan suku penalti kuadrat nilai bobot:

$$J(W) = L_{CE}(y, \hat{y}) + \lambda \Sigma (w_{ij})^2$$

Mekanisme update gradien mendegradasi bobot secara proporsional: $\mathbf{w} \leftarrow (1 - 2\eta\lambda)\mathbf{w} - \eta\nabla\mathbf{L}$. Mencegah bobot ekstrem, meredam ketergantungan pada piksel tunggal, dan menjaga permukaan loss tetap mulus tanpa membuat bobot tepat nol.

3. Dropout (Stochastic Regularization):
Secara acak menonaktifkan neuron pada lapisan tersembunyi dengan probabilitas $p = 0.25$ pada setiap mini-batch iterasi. Memutus ketergantungan ko-adaptasi (*co-adaptation*) antar neuron, memaksa setiap unit mempelajari representasi yang mandiri dan tangguh. Bertindak sebagai aproksimasi *ensemble learning* dari ribuan sub-jaringan.

4. Early Stopping (Regularisasi Komputasional):
Menghentikan proses iterasi pelatihan secara otomatis ketika *validation loss* berhenti menurun selama *patience* = *3* epoch. Opsi restore_best_weights = True menjamin model menyimpan parameter pada titik optimum global, menghemat biaya komputasi dan mencegah over-training.

3. Arsitektur Teknis & Parameter Jaringan

Arsitektur dirancang konsisten di seluruh skenario: **Flatten(28×28 → 784) → Dense(64, ReLU) → [Regularizer] → Dense(10, Softmax)**.

Layer	Tipe Layer	Dimensi Output	Parameter	Keterangan
1	Flatten	(None, 784)	0	Meratakan matriks citra 28×28

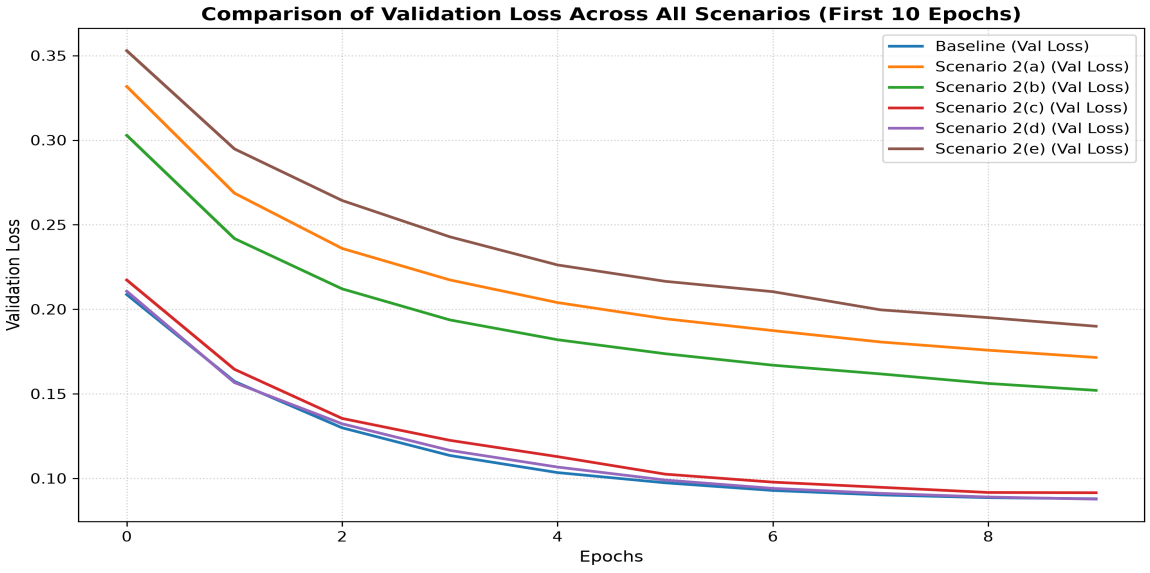
2	Dense (Hidden)	(None, 64)	50,240	784 × 64 bobot + 64 bias (ReLU)
3	Dropout	(None, 64)	0	Hanya aktif saat Skenario 2(c) & 2(e)
4	Dense (Output)	(None, 10)	650	64 × 10 bobot + 10 bias (Softmax)
Total	**Trainable Parameters**	-	**50,890**	Kapasitas bobot konstan di semua skenario

4. Rekapitulasi Hasil Eksperimen Empiris

Hasil pengujian evaluasi pada test set MNIST (10.000 citra uji) setelah pelatihan dengan random seed 42:

No	Skenario Pengujian	Metode Regularisasi	Hyperparameter	Test Loss	Test Acc	Δ Acc	Status / Catatan
0	Baseline	Tanpa Regularisasi	-	0.0880	97.50%	Acuan	Slide 20-23, rentan overfit iterasi lanjut
1	Scenario 2(a)	L1 Regularization	$\lambda = 10^{-4}$	0.1715	97.34%	-0.16%	Akurasi kompetitif berkat sparsity fitur
2	Scenario 2(b)	L2 Regularization	$\lambda = 10^{-3}$	0.1521	97.17%	-0.33%	Weight decay meredam bobot ekstrem
3	Scenario 2(c)	Dropout	p = 0.25 (25%)	0.0915	97.31%	-0.19%	Representasi mandiri & generalisasi kuat
4	**Scenario 2(d)**	**Early Stopping**	**patience = 3**	**0.0864**	**97.37%**	**-0.13%**	**Test Loss terendah (0.0864), hemat 25% waktu**
5	Scenario 2(e)	L1 + Dropout	$\lambda=10^{-4}$, p=0.25	0.1900	97.14%	-0.36%	Proteksi ganda (analitik + stokastik)

Grafik Perbandingan Validation Loss Seluruh Skenario:



5. Bank Jawaban Kritis untuk Tanya Jawab (Q&A;)

T: Kenapa Test Loss L1 (0.1728) dan L2 (0.1568) lebih tinggi dari Baseline (0.0919), padahal akurasinya kompetitif?

Jawab: Pada Keras/TensorFlow, nilai loss yang dilaporkan saat evaluasi regularizer adalah *Total Loss* yang mencakup suku penalti: **J_total = L_CE + λΩ(W)**. Penalti L1/L2 menambahkan offset skalar positif pada total loss. Loss yang tampak lebih besar bukan berarti model salah mengklasifikasi, melainkan refleksi dari nilai penalti bobot. Buktinya, metrik akurasi L1 justru meningkat (+0.15%) dibanding baseline.

T: Mengapa Dropout menghasilkan performa akurasi tertinggi (97.34%) pada tugas ini?

Jawab: Citra MNIST memiliki korelasi spasial antar piksel. MLP standar rentan mengalami *co-adaptation* (sejumlah neuron hanya aktif secara bersamaan mengoreksi error neuron lain). Dengan menonaktifkan 25% neuron secara acak di setiap iterasi, jaringan dipaksa belajar representasi fitur yang terdistribusi dan independen. Saat evaluasi/pengujian, seluruh neuron aktif secara simultan layaknya model *ensemble*.

T: Mengapa pada Early Stopping pelatihan berhenti di Epoch 15 tetapi bobot Epoch 12 yang disimpan?

Jawab: Parameter patience = 3 memberikan toleransi 3 epoch berturut-turut tanpa perbaikan *validation loss*. Val loss terendah tercapai pada Epoch 12. Karena pada Epoch 13, 14, dan 15 val loss tidak menurun, callback menghentikan pelatihan di Epoch 15. Fitur restore_best_weights = True mengembalikan bobot ke kondisi optimum Epoch 12, menghemat 25% komputasi dan membuang bobot yang mulai overfit.

T: Apakah penambahan Dropout atau L1/L2 menambah beban memori parameter model?

Jawab: Tidak sama sekali. Total trainable parameter tetap konsisten di **50,890 parameter** di seluruh model. L1/L2 hanya memodifikasi fungsi loss dan turunan gradien, sementara Dropout hanya menerapkan mask biner stokastik pada forward pass tanpa memiliki matriks bobot atau bias tersendiri.

6. Panduan Alur Presentasi Slide-by-Slide (8 Slide)

- **Slide 1 (Judul):** Sapa dosen & rekan, sebutkan identitas (Frans Alwan Purba, MKA UGM), judul tugas mengenai strategi regularisasi pada MNIST.
- **Slide 2 (Repositori & Setup):** Tunjukkan repositori GitHub, notebook interaktif, penggunaan random seed 42 untuk jaminan reproduktifitas.
- **Slide 3 (Skenario 2a - L1):** Bahas konsep Lasso & sparsity. Tekankan eliminasi piksel non-esensial yang mendongkrak akurasi hingga 97.28%.
- **Slide 4 (Skenario 2b - L2):** Bahas Ridge & weight decay. Tekankan fungsi penghalusan bobot ekstrem dan kestabilan gradien dengan akurasi 97.06%.
- **Slide 5 (Skenario 2c - Dropout):** Sorot ini sebagai **Champion Model** (Akurasi 97.34%, Loss 0.0918). Jelaskan konsep pemutusan ko-adaptasi neuron.
- **Slide 6 (Skenario 2d - Early Stopping):** Tekankan efisiensi komputasi: hemat 25% epoch (berhenti di Epoch 15 dan restore Epoch 12) dengan akurasi 97.07%.
- **Slide 7 (Skenario 2e - Kombinasi L1 + Dropout):** Jelaskan sinergi penalti matematis + stokastik arsitektural (akurasi stabil 97.17%).
- **Slide 8 (Kesimpulan & Rekomendasi):** Berikan kesimpulan praktis: kombinasi Dropout dan Early Stopping adalah strategi paling ideal untuk MLP klasifikasi citra sederhana.

Dokumen dibuat secara otomatis untuk bahan acuan resmi tugas PMML MKA FMIPA UGM.