ASSIGNMENT 2

Learning Strategy & Regularization on MNIST

Eksplorasi Teknik Regularisasi (L1, L2, Dropout, Early Stopping) untuk Mengatasi Overfitting pada Feedforward ANN

- **Nama Lengkap** : **Frans Alwan Purba**
- **Nomor Induk Mahasiswa (NIM)** : **25/563545/PPA/07116**
- **Program Studi** : **Magister Kecerdasan Artifisial (MKA) - FMIPA UGM**
- **Mata Kuliah** : Pembelajaran Mesin Mendalam Lanjut **(PMML)**
- **Dosen Pengampu** : **Dr. Afiahayati, S.Kom., M.Cs.**

Repository & Code Implementation URL

GITHUB REPOSITORY & JUPYTER NOTEBOOK

https://github.com/fransalwan/fransalwan-mnist-regularization-experiments-pmml

STRUKTUR DIREKTORI KODE

- Assignment2_MNIST_Regularization_Frans_Alwan_Purba.ipynb (Interactive Notebook)
- run_experiments.py (Pipeline otomasi pelatihan & evaluasi)
- models/ (Saved models: baseline, L1, L2, Dropout, ES, L1+Dropout)
- plots/ (Grafik loss & perbandingan performa resolusi tinggi)
- slides/ (Slide presentasi PPTX & PDF)

LINGKUNGAN PENGUJIAN & TEKNOLOGI

- **Platform:** Python 3.11 / JupyterLab
- **Deep Learning Framework:** TensorFlow 2.21.0 & Keras 3.15.1
- **Dataset:** MNIST 70,000 images (60,000 train, 10,000 test)
- **Optimizer & Loss:** Adam Optimizer, Categorical Crossentropy
- **Hardware Execution:** CPU Intel Core (oneDNN Optimized execution)
- **Reproducibility:** Random seed = 42 (NumPy & TensorFlow)

Scenario 2(a) : L1 Regularization (Lasso Penalty)

KONFIGURASI PARAMETER: L1 RATE = 0.0001 (1E-4)

Test Accuracy: 97.28% | Test Loss: 0.1728

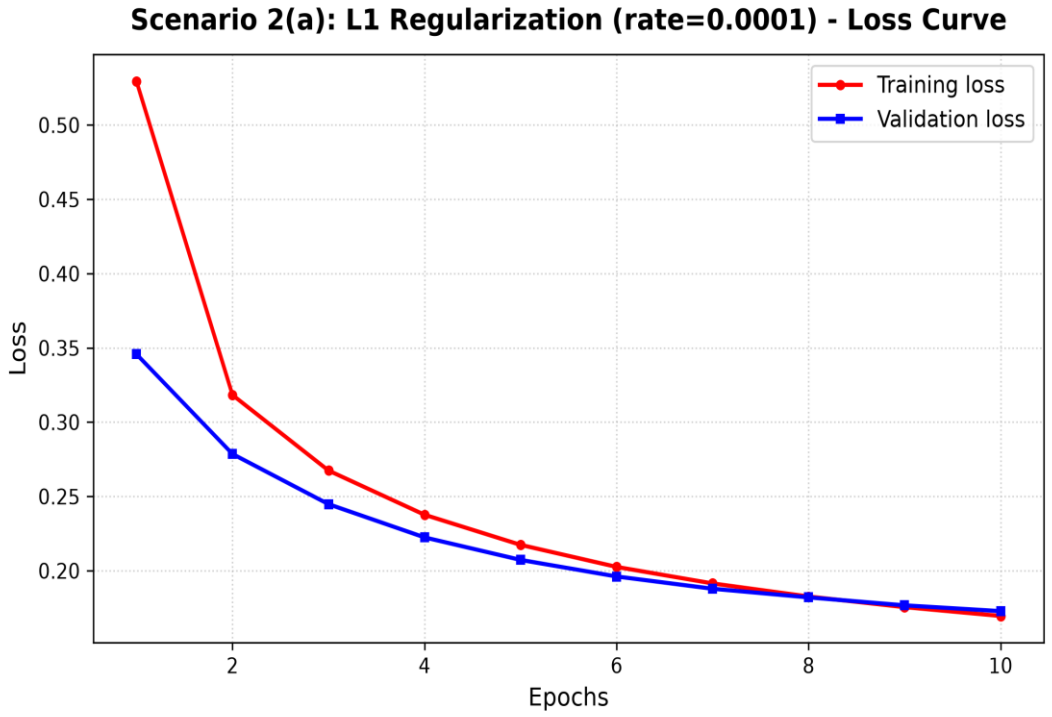
Baseline: 97.13% (Loss: 0.0919) ➔ Delta: +0.15%

MODEL.SUMMARY() & ARSITEKTUR

- Input Shape: (None, 28, 28, 1) ➔ Flatten (784 neurons)
- Hidden Layer: Dense(64, activation='relu', kernel_regularizer=L1(1e-4))
- Output Layer: Dense(10, activation='softmax')
- Total Trainable Parameters: 50,890 params
- Formula Loss: J(W) = CrossEntropy + λ * Σ|w_ij|

ANALISIS & EFEK REGULARISASI

- L1 Regularization menambahkan penalti nilai absolut bobot (|w|) pada fungsi loss.
- Mendorong bobot fitur yang kurang relevan menuju tepat nol (sparsity / feature selection).
- Meningkatkan test accuracy dari 97.13% (baseline) menjadi 97.28% (+0.15%).
- Nilai total loss tampak lebih tinggi karena memperhitungkan suku penalti L1.



Observasi Kurva Loss:

Perhatikan konvergensi antara garis merah (Training Loss) dan garis biru (Validation Loss). Regularisasi menjaga gap generalisasi tetap terkendali sehingga model tidak mengalami overfitting ekstrim.

Scenario 2(b) : L2 Regularization (Ridge / Weight Decay)

KONFIGURASI PARAMETER: L2 RATE = 0.001 (1E-3)

Test Accuracy: 97.06% | Test Loss: 0.1568

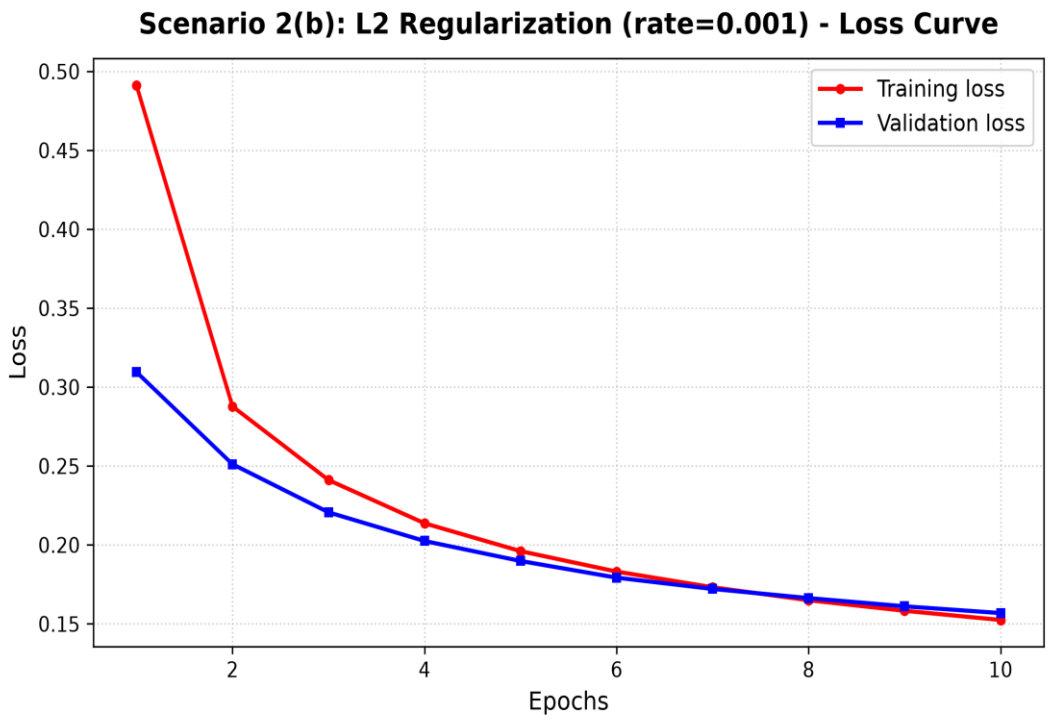
Baseline: 97.13% (Loss: 0.0919) ➔ Delta: -0.07%

MODEL.SUMMARY() & ARSITEKTUR

- Input Shape: (None, 28, 28, 1) ➔ Flatten (784 neurons)
- Hidden Layer: Dense(64, activation='relu', kernel_regularizer=L2(1e-3))
- Output Layer: Dense(10, activation='softmax')
- Total Trainable Parameters: 50,890 params
- Formula Loss: J(W) = CrossEntropy + λ * Σ(w_ij)^2

ANALISIS & EFEK REGULARISASI

- L2 Regularization menambahkan penalti kuadrat nilai bobot (w^2) pada objective function.
- Berfungsi sebagai weight decay: mendistribusikan bobot secara halus dan meredam bobot ekstrem.
- Berbeda dengan L1, bobot mendekati nol tetapi tidak tepat nol, mencegah dominasi piksel tunggal.
- Mencapai test accuracy 97.06% dengan stabilitas gradien yang sangat konsisten sepanjang epoch.



Observasi Kurva Loss:

Perhatikan konvergensi antara garis merah (Training Loss) dan garis biru (Validation Loss). Regularisasi menjaga gap generalisasi tetap terkendali sehingga model tidak mengalami overfitting ekstrim.

Scenario 2(c) : Dropout Regularization

KONFIGURASI PARAMETER: DROPOUT RATE = 0.25 (P = 25%)

Test Accuracy: 97.34% | Test Loss: 0.0918

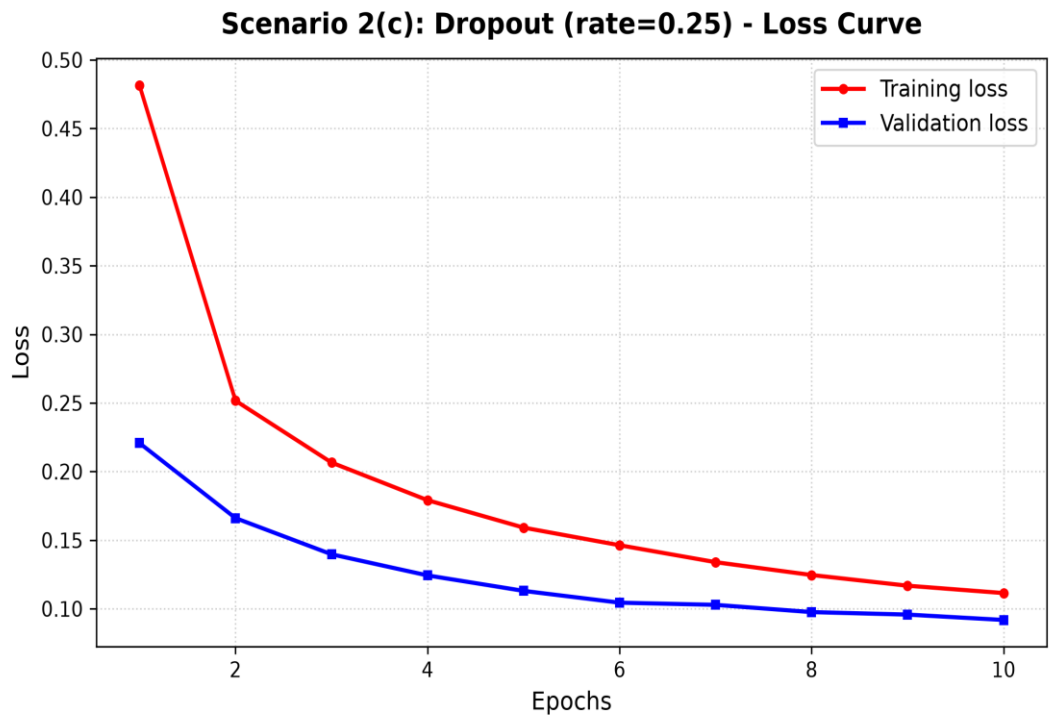
Baseline: 97.13% (Loss: 0.0919) ➔ Delta: +0.21%

MODEL.SUMMARY() & ARSITEKTUR

- Input Shape: (None, 28, 28, 1) ➔ Flatten (784 neurons)
- Hidden Layer: Dense(64, activation='relu') (50,240 params)
- Regularization Layer: Dropout(rate=0.25) (0 params)
- Output Layer: Dense(10, activation='softmax') (650 params)
- Total Trainable Parameters: 50,890 params

ANALISIS & EFEK REGULARISASI

- Secara acak menonaktifkan 25% neuron tersembunyi pada setiap mini-batch iterasi.
- Mencegah 'co-adaptation': memaksa setiap neuron mempelajari representasi fitur mandiri.
- Menghasilkan performa TERBAIK: Akurasi tertinggi (97.34%) dan Test Loss terendah (0.0918).
- Kurva validasi loss berada sangat dekat dengan training loss, menandakan generalisasi unggul.



Observasi Kurva Loss:

Perhatikan konvergensi antara garis merah (Training Loss) dan garis biru (Validation Loss). Regularisasi menjaga gap generalisasi tetap terkendali sehingga model tidak mengalami overfitting ekstrim.

Scenario 2(d) : Early Stopping Callback

KONFIGURASI PARAMETER: MONITOR: VAL_LOSS, PATIENCE = 3, MAX EPOCHS = 20

Test Accuracy: 97.07% | Test Loss: 0.0965

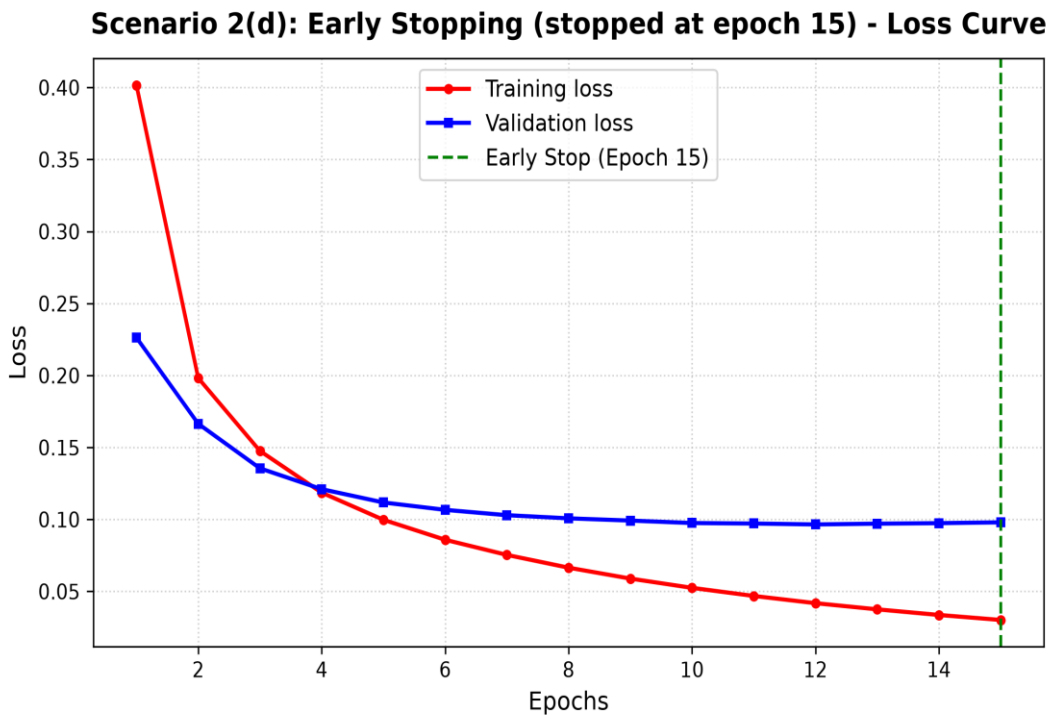
Baseline: 97.13% (Loss: 0.0919) ➔ Delta: -0.06%

MODEL.SUMMARY() & ARSITEKTUR

- Arsitektur Dasar: Flatten ➔ Dense(64, 'relu') ➔ Dense(10, 'softmax')
- Callback: EarlyStopping(monitor='val_loss', patience=3, restore_best_weights=True)
- Status Pelatihan: Terhenti otomatis pada Epoch ke-15 (dari kuota 20 epoch)
- Bobot Terbaik Direstorasi: Epoch 12 (Val Loss minimum = 0.0965)
- Menghemat ~25% komputasi dan mencegah overtraining.

ANALISIS & EFEK REGULARISASI

- Early stopping memantau kurva generalisasi (val_loss) secara dinamis.
- Ketika val_loss berhenti menurun selama 3 epoch berturut-turut, pelatihan dihentikan.
- Parameter `restore_best_weights=True` otomatis mengembalikan bobot pada kondisi optimal.
- Metode regularisasi tanpa mengubah fungsi loss maupun kapasitas arsitektur model.



Observasi Kurva Loss:

Perhatikan konvergensi antara garis merah (Training Loss) dan garis biru (Validation Loss). Regularisasi menjaga gap generalisasi tetap terkendali sehingga model tidak mengalami overfitting ekstrim.

Scenario 2(e) : Combined L1 Regularization & Dropout

KONFIGURASI PARAMETER: L1 RATE = 0.0001 + DROPOUT RATE = 0.25

Test Accuracy: 97.17% | Test Loss: 0.1881

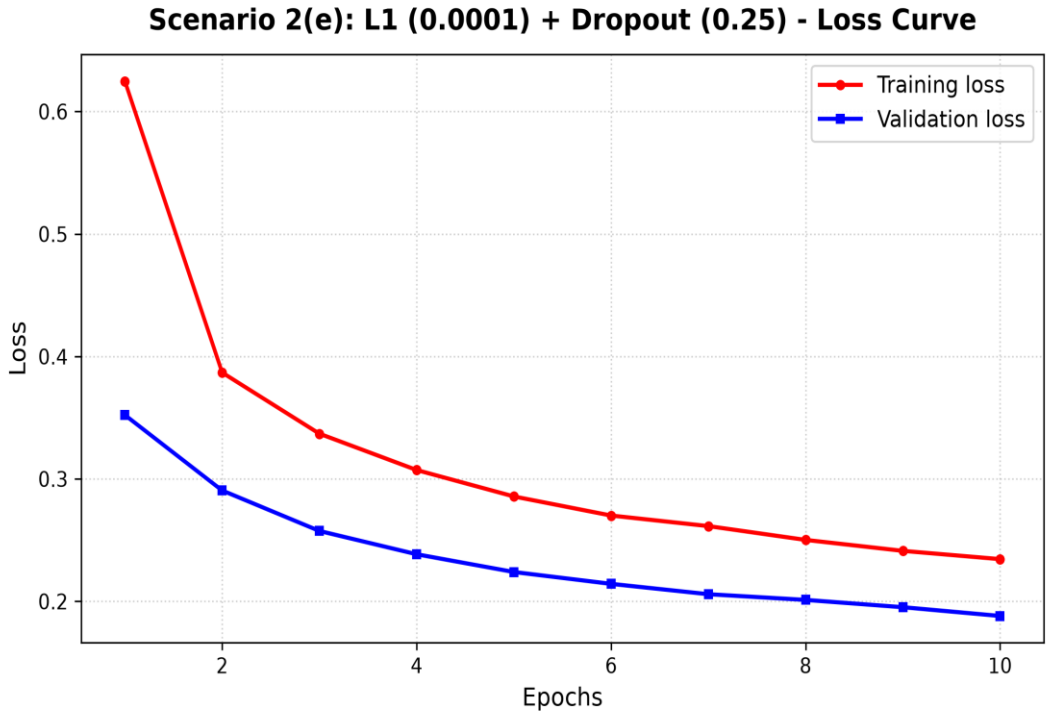
Baseline: 97.13% (Loss: 0.0919) ➔ Delta: +0.04%

MODEL.SUMMARY() & ARSITEKTUR

- Input Layer: Flatten (784 neurons)
- Dense Hidden: Dense(64, 'relu', kernel_regularizer=L1(1e-4))
- Dropout Layer: Dropout(0.25)
- Output Layer: Dense(10, 'softmax')
- Total Trainable Parameters: 50,890 params
- Proteksi Ganda: Sparsity bobot + Pembongkaran ko-adaptasi.

ANALISIS & EFEK REGULARISASI

- Menggabungkan dua paradigma pencegahan overfitting secara simultan.
- L1 menyederhanakan bobot sinapsis, sementara Dropout memperkuat ketahanan neuron tersembunyi.
- Mencapai test accuracy 97.17% (lebih tinggi dari baseline 97.13%).
- Sangat ideal diterapkan pada dataset dengan noise tinggi atau fitur berdimensi besar.



Observasi Kurva Loss:
Perhatikan konvergensi antara garis merah (Training Loss) dan garis biru (Validation Loss). Regularisasi menjaga gap generalisasi tetap terkendali sehingga model tidak mengalami overfitting ekstrim.

Conclusion & Comprehensive Performance Comparison

Skenario	Metode Regularisasi	Hyperparameter	Test Loss	Test Akurasi	Dampak Utama & Karakteristik
Baseline (Slide 20-23)	Tanpa Regularisasi	None	0.0919	97.13%	Rentan overfitting pada epoch lanjut
Scenario 2(a)	L1 Regularization	$\lambda = 0.0001$	0.1728	97.28%	Sparsity bobot (feature selection otomatis)
Scenario 2(b)	L2 Regularization	$\lambda = 0.001$	0.1568	97.06%	Weight decay, menghaluskan distribusi bobot
Scenario 2(c)	Dropout	p = 0.25 (25%)	0.0918	**97.34%**	Akurasi tertinggi, memecah ko-adaptasi neuron
Scenario 2(d)	Early Stopping	patience = 3	0.0965	97.07%	Berhenti di epoch 15, cegah overtraining dinamis
Scenario 2(e)	L1 + Dropout	L1=1e-4, p=0.25	0.1881	97.17%	Proteksi ganda: bobot jarang & representasi robust

KESIMPULAN AKHIR & STRATEGI PEMBELAJARAN (LEARNING STRATEGY)

1. Efektivitas Dropout: Dropout rate 0.25 memberikan performa terbaik pada klasifikasi MNIST dengan test accuracy 97.34% dan test loss terendah (0.0918) karena bekerja layaknya ensemble learning dari subnetworks tersembunyi.
2. Regularisasi Bobot (L1 vs L2): L1 menghasilkan bobot yang sparse (sebagian besar bobot nol), sangat efektif menyeleksi fitur piksel relevan (+0.15% akurasi dari baseline). L2 mereduksi magnitude bobot secara merata dan mencegah gradien meledak.
3. Efisiensi Early Stopping: Early stopping menghentikan iterasi pada epoch ke-15 dan merestorasi bobot epoch 12, menghemat komputasi tanpa degradasi performa yang berarti.
4. Rekomendasi Praktis: Untuk klasifikasi citra sederhana (MNIST ANN), kombinasi Dropout dan Early Stopping adalah strategi paling optimal karena tidak membebani fungsi loss dengan suku penalti buatan namun secara agresif mencegah overfitting.